

Neural Information Retrieval

David Guaty Domínguez C512
Adrián Rodríguez Portales C512
Rodrigo D. Pino Trueba C512

June 2022

1 Introducción

A lo largo de la historia de la humanidad, el proceso de almacenar y recuperar la información ha sido una tarea bastante difundida. Sin embargo con el surgimiento de Internet y del *Big Data*, los volúmenes de información actuales son cada vez más grandes y se hace necesario el surgimiento de herramientas más sofisticadas para poder satisfacer estas necesidades. El estudio de esta área se le conoce como Recuperación de Información (*Information Retrieval*). Entre los modelos clásicos utilizados se encuentran el booleano y el vectorial. Ambos modelos presentan ventajas en determinadas situaciones, pero en muchos escenarios no logran cumplir con los requerimientos del sistema.

La aparición del aprendizaje automático (*machine learning*) y ,en especial, del aprendizaje profundo (*deep learning*), ha permitido revolucionar la industria y la ciencia . Los sistemas de recuperación de información no se han quedado atrás. El enfoque conocido como *Learning to Rank* [1] usa técnicas de aprendizaje automático para la tarea de recuperar información. Existen tres formas principales de resolver este problema:

- *pointwise*: Este enfoque es el más sencillo de implementar y fue el primero en proponerse para las tareas de *Learning to Rank*.
- *pairwise*: El problema con el enfoque anterior es que se necesita la relevancia absoluta de un documento con respecto a una consulta. Sin

embargo, en muchos escenarios esta información no está disponible, entonces lo que se puede saber es, por ejemplo, que documento tiene mayor relevancia de una lista según la selección de un usuario

- *listwise*: Este enfoque es el más difícil, pero también el más directo. A diferencia de los dos anteriores, donde el problema se reduce a una regresión o clasificación, este trata de resolver el problema de ordenación directamente.

Dentro de los modelos de aprendizaje automático más usados recientemente para el proceso de *ranking*, se encuentran las redes neuronales. A la aplicación de este conjunto de técnicas en la recuperación de información se le conoce como *Neural Information Retrieval* [3]. En este trabajo usaremos este enfoque y compararemos los resultados con un modelo de recuperación de información clásico (vectorial).

2 Diseño del sistema de recuperación de información

TODO: Hablar un poco de la arquitectura general de la aplicación

2.1 Preprocesamiento de los datos

Los dataset utilizados fueron preprocesados para obtener aquellas palabras que tienen mayor semántica. Durante este proceso se realizaron dos tareas:

- Eliminación de *stopwords*: los *stopwords* son términos muy comunes que brindan poca información semántica en un texto o documento. Generalmente suelen ser adverbios, pronombres y artículos.
- *Lemmatization*: este proceso consiste en llevar a las palabras a su raíz gramatical, haciendo análisis morfológico de los términos y eliminando cualquier inflexión. Esto permite indexar términos con igual semántica como uno solo .

Ambas tareas se hicieron con la biblioteca de Python *Spacy*

2.2 Modelo vectorial

El modelo vectorial[2] es un modelo algebraico que representa los documentos y la consulta como vectores con pesos. Cada término indexado representa una dimensión del vector, por lo que el vocabulario del corpus es quien define la dimensión del espacio vectorial.

Para el cálculo de los pesos existen varias formas. Una de las más usadas es *tf-idf*. Esta tiene entre sus ventajas que es fácil de computar. Sin embargo, como está basado en el modelo *bag of words*, no tiene en cuenta el orden de las palabras en el texto.

Para calcular el *tf* se utilizó la siguiente fórmula:

$$tf_{ij} = K + \frac{(1 - K)freq_{ij}}{\max_i freq_{ij}}$$

En el caso del *idf* se utilizó:

$$idf_i = \log \frac{N}{n_i}$$

donde N es el total de documentos en el corpus y n_i es la cantidad de documentos donde aparece el término i . Luego con estos valores los pesos se obtenían como $w_{ij} = tf_{ij} * idf_{ij}$.

Finalmente para obtener la similitud entre la consulta y los documentos se usó el coseno del ángulo :

$$sim(d_j, q) = \frac{d_j \cdot q}{|d_j||q|}$$

2.3 Modelo con redes neuronales

3 Análisis de los resultados

4 Conclusiones